

技术可行性报告：面向动态物体感知的世界模型

——超越静态点云渲染条件

Motion-Aware World Models: Beyond Static Point Clouds

1. 背景与动机 (Background & Motivation)

1.1 问题陈述

实时4D世界模拟器的核心挑战在于生成时间一致且物理合理的动态场景。InSpatio-World系统基于Wan2.1-T2V-1.3B backbone构建了一个causal autoregressive推理框架，通过点云渲染提供几何条件信号。然而，当前系统在Object Motion指标上仅获得60.21分（满分100），成为整体性能的主要瓶颈。相比之下，3D Consistency达到84.18，表明静态几何建模已相对成熟，但动态物体运动建模存在根本性不足。

这一缺陷的根源在于渲染条件管线的设计哲学：系统采用静态点云 (static point clouds) 逐帧渲染，每帧独立加载PLY文件，通过z-buffer splatting生成render condition。这种设计隐含了一个关键假设——场景中所有物体在局部时间窗口内保持几何静止。对于自动驾驶场景中的行人、车辆等动态物体，静态点云渲染完全无法提供其运动轨迹、速度方向等动力学信息。模型被迫仅从历史生成帧中“猜测”动态物体的未来运动，而无法从条件信号中获得显式的运动引导。

1.2 相关工作

动态NeRF与4D表征：D-NeRF (Pumarola et al., 2021)、HyperNeRF (Park et al., 2021) 以及近期的4D Gaussian Splatting (Wu et al., 2024) 通过时间形变场 (deformation field) 建模动态场景。这些方法证明了将场景显式分解为静态背景与动态前景的有效性，但它们主要面向重建任务而非生成任务。

视频物体分割 (Video Object Segmentation): SAM2 (Ravi et al., 2024) 提供了强大的视频级物体分割能力, 能够在时间维度上一致性地追踪和分割动态物体。Cutie (Cheng et al., 2024) 等方法进一步提升了长视频中的分割鲁棒性。这些工具为动态区域识别提供了即用型 (off-the-shelf) 解决方案。

运动条件生成: MotionCtrl (Wang et al., 2024)、DragAnything (Wu et al., 2024) 等工作展示了将运动轨迹作为生成条件的可行性。然而, 这些方法通常需要用户显式指定运动轨迹, 而非从场景观测中自动推断。

Self-Forcing与Causal Forcing: Self-Forcing (arXiv:2412.07772) 通过将模型自身的预测作为后续帧的输入来缓解训练-推理分布偏移问题。ICML 2026提出的Causal Forcing进一步改进了因果一致性, 但两者均未显式处理动态物体运动建模。

1.3 根本性分析: 为何静态点云无法捕获动力学

从信息论角度分析, 静态点云渲染条件 $\mathbf{R}_t$ 编码的是时刻 t 的瞬时几何 (instantaneous geometry):

$$\mathbf{R}_t = \text{ZBuffer}(\mathbf{P}_t, \mathbf{K}_t, \mathbf{E}_t)$$

其中 $\mathbf{P}_t$ 为点云, $\mathbf{K}_t$ 和 $\mathbf{E}_t$ 分别为相机内参和外参。 $\mathbf{R}_t$ 不包含任何关于 $\frac{\partial \mathbf{P}}{\partial t}$ (点云时间导数, 即运动场) 的信息。因此, 动态物体的运动方向、速度、加速度等一阶及高阶动力学信息对条件网络完全不可见。模型必须仅依赖DiT transformer blocks中的temporal attention从历史生成帧中隐式推断运动模式——这对于复杂多体运动场景是严重不足的。

2. 方法 (Method)

2.1 系统总览

我们提出一个三阶段渐进式增强方案, 将InSpatio-World从"静态几何感知"升级为"动态运动感知"世界模型:

- 贡献一 (Contribution 1): Dynamic Object-Aware Render Conditioning —— 在渲染条件管线中引入动态物体分割与运动编码
- 贡献二 (Contribution 2): Dual-Region Training with Static Flow + Dynamic Motion Loss —— 区域感知的双路径训练策略

- 贡献三 (Contribution 3): Causal Forcing Training Upgrade with Motion-Aware Scheduling —— 基于Causal Forcing的运动感知训练升级

2.2 贡献一：动态物体感知渲染条件 (Dynamic Object-Aware Render Conditioning)

2.2.1 动态分割管线

给定输入视频帧序列 $I_{t=1}^T$ ，我们首先通过SAM2获得逐帧的动态/静态区域分割：

$$M_t^{\text{dyn}} = \text{SAM2}_{\text{track}}(\{I_t\}, \mathcal{P}_{\text{init}})$$

其中 $M_t^{\text{dyn}} \in 0, 1^{H \times W}$ 为动态区域掩码， $\mathcal{P}_{\text{init}}$ 为初始帧中通过启发式规则（如光流幅度阈值）自动检测的动态物体prompt。静态区域掩码为 $M_t^{\text{sta}} = 1 - M_t^{\text{dyn}}$ 。

为降低对单一分割模型的依赖，我们引入运动一致性验证 (motion consistency verification)：

$$M_t^{\text{dyn, verified}} = M_t^{\text{dyn}} \cdot 1 [\|\mathbf{F}_t(x, y)\| > \tau_{\text{flow}}]$$

其中 $\mathbf{F}_t$ 为RAFT (Teed & Deng, 2020) 估计的光流， τ_{flow} 为运动阈值。此步骤可过滤分割误检（如静态物体被误标为动态）。

2.2.2 运动编码通道

对于已分割的动态区域，我们编码以下运动特征为额外条件通道：

光流通道 (Optical Flow Channels)：前向光流 $\mathbf{F}_t^{\text{fwd}} \in \mathbb{R}^{2 \times H \times W}$ 和后向光流 $\mathbf{F}_t^{\text{bwd}} \in \mathbb{R}^{2 \times H \times W}$ ，仅在动态区域内有效：

$$\mathbf{F}_t^{\text{masked}} = \mathbf{F}_t \odot M_t^{\text{dyn}}$$

物体级运动向量 (Object-Level Motion Vectors)：对每个动态物体实例 k ，计算其质心速度 $\mathbf{v}_k = (\Delta x_k, \Delta y_k)$ ，并将其广播至该物体的mask区域内，形成 $\mathbf{V}_t \in \mathbb{R}^{2 \times H \times W}$ 。

运动幅度通道 (Motion Magnitude Channel)： $|\mathbf{F}_t| \in \mathbb{R}^{1 \times H \times W}$ ，提供标量运动强度信息。

动态区域标识 (Dynamic Region Indicator)： $M_t^{\text{dyn}} \in \mathbb{R}^{1 \times H \times W}$ ，显式告知模型哪些区域为动态。

综合以上通道，额外条件通道数为 $K = 2 + 2 + 1 + 1 = 6$ 。

2.2.3 修改后的模型架构

原始InSpatio-World的 `patch_embedding` 接受36通道输入:

$$\mathbf{z}_{\text{input}} = \text{Cat}[\mathbf{x}_{\text{latent}}^{16}, \mathbf{m}_{\text{mask}}^4, \mathbf{r}_{\text{render}}^{16}] \in \mathbb{R}^{36 \times T \times H' \times W'}$$

扩展后:

$$\mathbf{z}_{\text{input}}^{\text{new}} = \text{Cat}[\mathbf{x}_{\text{latent}}^{16}, \mathbf{m}_{\text{mask}}^4, \mathbf{r}_{\text{render}}^{16}, \mathbf{c}_{\text{motion}}^K] \in \mathbb{R}^{(36+K) \times T \times H' \times W'}$$

对应地, CausalWanModel中的 `patch_embedding` Conv3d层的 `in_channels` 从36扩展为42:

```
self.patch_embedding = nn.Conv3d(
    in_channels=42, # 36 + 6 motion channels
    out_channels=2048,
    kernel_size=(1, 2, 2),
    stride=(1, 2, 2)
)
```

为保持预训练权重可用, 新增通道的权重初始化为零 (zero-initialization), 确保初始时刻模型行为与原始模型一致:

$$W_{\text{new}}[:, 36 : 42, :, :, :] = 0$$

2.2.4 推理时的运动条件生成

在autoregressive推理中, 运动条件需从已生成帧中在线估计。具体流程:

1. 对最近生成的context frames (最多6帧) 运行轻量级光流估计 (如 FlowFormer-small)
2. 对context frames运行SAM2 tracking获得动态区域mask
3. 编码运动通道并送入`patch_embedding`

这引入了额外的推理开销, 我们将在第4节进行详细分析。

2.3 贡献二: 双区域训练策略 (Dual-Region Training)

2.3.1 设计动机

静态区域与动态区域对生成模型提出了矛盾的学习要求:

- 静态区域: 需要严格的几何一致性, 点云flow matching提供了强约束

- 动态区域：需要运动灵活性，过强的几何约束反而限制了动态生成能力

因此，我们提出区域分离的损失函数设计。

2.3.2 静态区域损失

对于静态区域，保留原始的flow matching loss并增加点云几何一致性正则化：

$$\mathcal{L}_{\text{static}} = \mathbb{E}_{t,\epsilon} [\|M^{\text{sta}} \odot (\mathbf{v}_\theta(\mathbf{z}_t, t) - \mathbf{v}_{\text{target}})\|_2^2] + \lambda_{\text{geo}} \mathcal{L}_{\text{geo}}$$

其中 $\mathbf{v}_\theta$ 为模型预测的velocity field, $\mathbf{v}_{\text{target}}$ 为ground truth velocity, $\mathcal{L}_{\text{geo}}$ 为基于点云重投影的几何一致性损失。

2.3.3 动态区域损失

对于动态区域，我们设计了包含运动预测的复合损失：

$$\mathcal{L}_{\text{dynamic}} = \mathcal{L}_{\text{flow}}^{\text{dyn}} + \lambda_{\text{motion}} \mathcal{L}_{\text{motion}} + \lambda_{\text{temp}} \mathcal{L}_{\text{temporal}}$$

其中：

- $\mathcal{L}_{\text{flow}}^{\text{dyn}}$ 为动态区域的标准flow matching loss（不加几何约束）
- $\mathcal{L}_{\text{motion}}$ 为运动预测损失，通过辅助head预测下一帧的动态物体位移：

$$\mathcal{L}_{\text{motion}} = \|\hat{\Delta}_{\text{obj}} - \Delta_{\text{obj}}^{\text{gt}}\|_1$$

- $\mathcal{L}_{\text{temporal}}$ 为时间平滑损失，鼓励动态区域的运动轨迹平滑：

$$\mathcal{L}_{\text{temporal}} = \left\| \frac{\partial^2 \hat{\mathbf{p}}_{\text{obj}}}{\partial t^2} \right\|_2^2$$

2.3.4 综合训练目标

最终训练目标为两个区域损失的加权和：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{static}} + \alpha \mathcal{L}_{\text{dynamic}}$$

权重 α 采用动态调度策略：训练初期 $\alpha = 0.5$ （平衡学习），后期逐步增大至 $\alpha = 1.5$ （强化动态建模）。

2.3.5 辅助Motion Head设计

在CausalWanModel的第24个transformer block之后（共32 blocks），分出一个轻量级辅助分支：

$$\mathbf{h}_{24} \xrightarrow{\text{Linear}(2048,512)} \xrightarrow{\text{ReLU}} \xrightarrow{\text{Linear}(512,2)} \hat{\Delta}_{\text{obj}}$$

该head仅在训练时启用，推理时移除，不增加推理开销。

2.4 贡献三：Causal Forcing训练升级 (Causal Forcing Training Upgrade)

2.4.1 从Self-Forcing到Causal Forcing

当前InSpatio-World基于Self-Forcing训练，其核心思想是在训练中使用模型自身预测作为后续帧输入：

$$\hat{\mathbf{z}}_{t+1} = \text{denoise}(\mathbf{z}_{t+1}^{\text{noisy}}, \text{context} = \hat{\mathbf{z}}_{1:t})$$

Causal Forcing (ICML 2026) 在此基础上引入了更严格的因果性约束：每个frame-block的生成仅依赖其因果前序帧，且通过重参数化梯度传播确保长程依赖的有效学习。

我们将InSpatio-World的训练框架升级为Causal Forcing，具体修改包括：

1. KV cache的梯度传播：允许梯度通过KV cache向前传播（当前实现中KV cache在推理时detach）
2. 因果一致性正则化：

$$\mathcal{L}_{\text{causal}} = \sum_{t=2}^T \text{KL} \left(p_{\theta}(\mathbf{z}_t | \mathbf{z}_{1:t-1}^{\text{gt}}) \| p_{\theta}(\mathbf{z}_t | \hat{\mathbf{z}}_{1:t-1}) \right)$$

2.4.2 运动感知噪声调度 (Motion-Aware Noise Scheduling)

标准flow matching对所有区域使用均匀噪声调度。我们提出区域自适应的噪声级别：

$$\sigma_t^{\text{region}}(x, y) = \begin{cases} \sigma_t^{\text{base}} & \text{if } (x, y) \in M^{\text{sta}} \\ \sigma_t^{\text{base}} \cdot (1 + \beta \cdot \|\mathbf{F}(x, y)\|) & \text{if } (x, y) \in M^{\text{dyn}} \end{cases}$$

其直觉是：运动越剧烈的区域，其生成难度越高，需要更多的去噪步数（对应更高的初始噪声）。参数 β 控制噪声放大系数，典型值为 $\beta \in [0.1, 0.5]$ 。

2.4.3 课程学习策略 (Curriculum Learning)

训练分为三个阶段：

Phase 1 (静态适应, 50K steps): 仅使用静态场景数据，运动通道全零，确保模型在引入新通道后仍保持原有静态生成能力。损失仅含 $\mathcal{L}_{\text{static}}$ 。

Phase 2 (简单动态, 100K steps): 引入包含单一动态物体的场景（如单辆行驶中的汽车），运动通道激活， α 从0线性增至0.5。

Phase 3 (复杂动态, 150K steps): 使用包含多个动态物体、遮挡、交互等复杂场景的数据， α 从0.5增至1.5，启用motion-aware noise scheduling。

总训练量约300K steps，batch size 8（受限于额外通道的显存开销），预计需要8xH100约14天。

2.5 推理流程

完整推理流程如下：

- 加载初始context frames（用户提供或从首帧生成）
- 对context frames运行SAM2 + RAFT获得动态分割与光流
- 编码运动通道 $\mathbf{c}_{\text{motion}}^K$
- 与原有render condition拼接，送入CausalWanModel
- Causal autoregressive生成下一frame-block（1560 tokens）
- 更新KV cache，将生成帧加入context
- 对新生成帧重新运行分割与光流，回到步骤3

3. 实验计划 (Experiments Plan)

3.1 评估指标

我们采用与InSpatio-World相同的benchmark评估体系，重点关注以下指标：

指标	当前值	目标值	改进幅度
Object Motion	60.21	68+	+13%+
Dynamic Score	68.72	75+	+9%+
Static Content	54.50	55+	保持/微升
3D Consistency	84.18	83+	保持

指标	当前值	目标值	改进幅度
Overall Quality	--	显著提升	--

注意：由于引入动态建模，静态内容和3D一致性可能有轻微波动，但不应显著下降。

3.2 消融实验设计

我们设计以下消融实验以验证各组件的贡献：

Ablation A - 通道贡献分析：

- A1: 仅添加光流通道 (+2 channels, in_dim=38)
- A2: 仅添加动态mask通道 (+1 channel, in_dim=37)
- A3: 添加光流+mask+运动幅度 (+5 channels, in_dim=41)
- A4: 全部6通道 (完整方案, in_dim=42)

Ablation B - 训练策略分析：

- B1: 统一损失 (无区域分离)，全部区域同一loss
- B2: 仅静态区域加几何约束 (无动态专用loss)
- B3: 完整dual-region训练 (完整方案)
- B4: B3 + Causal Forcing升级

Ablation C - 分割方法鲁棒性：

- C1: 使用GT动态分割 (oracle, 评估上界)
- C2: 使用SAM2分割
- C3: 使用简单光流阈值分割 (无SAM2依赖)
- C4: 使用随机mask (negative control, 评估下界)

Ablation D - 课程学习分析：

- D1: 无课程，直接在复杂数据上训练
- D2: 两阶段课程 (合并Phase 2和Phase 3)
- D3: 完整三阶段课程

3.3 基线方法 (Baselines)

1. InSpatio-World Vanilla: 原始系统，36通道输入，Self-Forcing训练
2. Static Render Only (Enhanced): 优化后的静态点云渲染 (更密集的点云、更好的深度估计)，但无动态建模

3. Motion Conditioning Only: 添加运动通道但不做区域分割和dual-region训练
4. Self-Forcing + Motion: 使用Self-Forcing（非Causal Forcing）配合完整运动条件方案
5. DragAnything-style: 将动态物体轨迹作为类似DragAnything的控制信号注入

3.4 数据集要求

训练数据需满足以下条件:

- 包含显著动态物体运动的视频（行人、车辆、动物等）
- 视频分辨率不低于720p，时长不少于3秒
- 需要相机内外参标注（用于点云重建的一致性）
- 建议数据量：10K+ 视频clips

具体数据来源:

- nuScenes（自动驾驶场景，含丰富动态物体标注）
- KITTI（经典自动驾驶数据集，含光流GT）
- YouTube-VOS / DAVIS（通用视频物体分割数据，含mask标注）
- 自采集数据：使用Structure-from-Motion pipeline获取相机参数

数据预处理pipeline:

1. DA3 depth estimation → 点云重建
2. SAM2 动态物体分割 → 静态/动态区域mask
3. RAFT 光流估计 → 运动通道编码
4. 所有中间结果缓存至磁盘，避免训练时重复计算

预处理单条视频（5秒@30fps）预计耗时约45秒（SAM2 ~20s, RAFT ~15s, 点云渲染~10s），10K视频全量预处理约需125 GPU-hours。

3.5 评估协议

除定量指标外，我们还将进行以下定性评估:

- 动态物体轨迹一致性：可视化生成视频中动态物体的运动轨迹，对比GT轨迹的偏差
- 遮挡处理能力：测试物体相互遮挡时的生成质量
- 新运动模式泛化：测试训练中未见过的运动模式（如U-turn、急停）
- 长视频一致性：生成100+帧的长视频，评估运动质量是否随时间退化

3.6 计算资源估算

实验项	GPU需求	预计时间
数据预处理	4xA100	3天
Phase 1训练	8xH100	4天
Phase 2训练	8xH100	5天
Phase 3训练	8xH100	5天
消融实验(12组)	8xH100	24天
评估与推理	4xH100	3天
总计	--	~44天

4. 可行性评估 (Feasibility Assessment)

4.1 实现复杂度分析

与Direction 1 (Render-Aware Training) 相比，本方案的实现复杂度显著更高：

Direction 1 的工作量：

- 修改patch_embedding + 添加辅助loss
- 预计3-4个月可完成

本方案的工作量：

- 需要集成外部模型（SAM2, RAFT/FlowFormer）
- 需要修改模型架构（patch_embedding扩展, 辅助head）
- 需要重新设计训练管线（dual-region loss, curriculum）
- 需要修改推理流程（在线分割与光流估计）
- 需要大规模数据预处理pipeline
- 预计 6-8个月 完成全部工作

复杂度约为Direction 1的 2-2.5倍。

4.2 外部模型依赖风险

外部模型	用途	风险级别	缓解策略
SAM2	动态物体分割	中	可退化为光流阈值方案
RAFT/FlowFormer	光流估计	低	成熟技术，多种开源实现
DA3	深度估计	低	已在现有系统中使用

关键风险：SAM2的分割质量直接影响动态区域的识别准确度。根据Ablation C的设计，若SAM2分割质量不达标（C2显著低于C1 oracle），则可能需要：

- 在特定域（如自动驾驶）上对SAM2进行fine-tune
- 引入时间一致性后处理（temporal consistency post-processing）
- 退化为基于光流的简单分割方案

4.3 错误传播风险

动态分割错误会以两种方式传播至生成质量：

1. False Positive（静态区域被误判为动态）：模型收到虚假运动信号，可能导致本应静止的物体产生抖动。缓解措施：运动一致性验证（光流阈值二次确认）。
2. False Negative（动态物体被漏检）：模型在动态区域缺失运动条件，退化为vanilla行为。影响相对温和——最坏情况等价于原始系统。

4.4 推理速度影响

当前系统在H系列GPU上达到24fps。引入在线分割与光流后的额外开销：

组件	单帧耗时 (H100)	影响
SAM2推理 (tracking mode)	~15ms	轻微
RAFT光流 (轻量版)	~8ms	轻微
运动通道编码	~2ms	可忽略
patch_embedding (42 vs 36 ch)	~0.5ms	可忽略
总额外开销	~25ms/frame	fps: 24 → ~18

推理速度从24fps降至约18fps（降低约25%）。潜在优化方向：

- 每N帧运行一次SAM2（如每3帧），中间帧通过track propagation获得mask

- 使用TensorRT加速SAM2和RAFT
- 运动通道的temporal downsampling（每2帧计算一次，中间线性插值）

经优化后预计可恢复至20-22fps范围。

4.5 时间线与里程碑

阶段	时间	里程碑
Month 1-2	基础设施搭建	SAM2/RAFT集成，数据预处理pipeline
Month 2-3	架构修改	模型扩展通道，zero-init验证
Month 3-4	Phase 1+2训练	静态适应+简单动态验证
Month 4-5	Phase 3训练+消融	复杂动态训练，消融实验
Month 5-6	评估与优化	全面evaluation，速度优化
Month 6-7	论文撰写	实验补充，论文完成
Month 7-8	投稿准备	Review应对，camera-ready

目标会议：ICLR 2027（预计截止日期2026年10月）或 CVPR 2027（截止日期2026年11月）。

4.6 综合可行性判断

可行性评级：中高 (Medium-High)

有利因素：

- 核心假设（动态分割信息有助于运动生成）有充分的先验工作支持
- 所有外部依赖均有成熟开源实现
- Zero-init策略确保了安全的渐进式开发（任何阶段失败可回退）
- Object Motion指标当前远低于其他指标，改进空间明确

不利因素：

- 实现复杂度显著高于替代方案
- 对数据质量和预处理pipeline的要求高
- 推理速度降低可能影响实时性声称
- 多组件系统的debugging和ablation成本高

建议决策路径：

若团队资源充足（2+全职研究员、充足GPU）且追求高影响力工作，推荐采纳本方案。其核心创新（将动态感知从隐式学习升级为显式条件建模）具有明确的方法论贡献，且Object Motion 60.21 → 68+的提升具有显著的benchmark竞争力。

若资源有限或时间紧迫，建议先完成Direction 1 (Render-Aware Training) 作为"快速胜利"投稿，同时将本方案作为长期研究方向持续推进。两个方向并不互斥——Direction 1 的改进可作为本方案的更强baseline。

5. 结论

本报告提出了"Motion-Aware World Models: Beyond Static Point Clouds"的完整技术方案，通过三个互补贡献（动态物体感知渲染条件、双区域训练策略、Causal Forcing升级）系统性地解决InSpatio-World在Object Motion指标上的根本性不足。方案在技术上可行，预期可将Object Motion从60.21提升至68+，Dynamic Score从68.72提升至75+。主要风险在于实现复杂度和推理速度降低，建议在6-8个月的时间框架内逐步推进，目标投稿ICLR 2027或CVPR 2027。

报告完成日期: 2026年6月

目标系统: InSpatio-World (CausalWanModel, 1.3B parameters)

研究方向等级: 高风险-高回报 (High Risk - High Reward)