

遮挡鲁棒的多人绝对3D位姿估计：几何先验增强的RootNet

技术可行性报告 · 2026-07-28 · idea: 遮挡鲁棒的多人绝对3D位姿估计_几何先验增强的RootNet.md · ReAct 写作（边写边查证 papers/cards/codebases） · model: qmodel_preview 毕业设计技术可行性报告 目标会议/答辩：本科毕业论文答辩（约4个月周期） 训练资源：实验室单卡（≤24 GB显存）

1. 背景与动机

1.1 问题陈述

多人绝对3D位姿估计要求从单目RGB图像/视频中同时恢复场景中每个人的完整三维关节坐标（相机坐标系），其核心难点在于绝对根深度的确定——即每人距相机的真实距离。Moon等人（2019）提出的3DMPPE框架（DetectNet→RootNet→PoseNet）以面积比距离度量 $k = \sqrt{f_x \cdot f_y \cdot A_{\text{real}} / A_{\text{img}}}$ 估计根深度 Z_R ，成为该任务的标准top-down管线。然而该管线存在两个结构性瓶颈：

瓶颈一：根深度在遮挡/截断下崩溃。 RootNet的距离度量依赖成像面积 A_{img} 的准确估计。当人体被他人/物体遮挡或画面截断时，检测框面积严重偏离真实投影面积，导致深度估计失效。Moon等人（2019）原文图4已给出反例。Root-GAST-Net（2022）在Human3.6M上的实验表明，RootNet原版的MRPE达289 mm，而其改进版仍为178 mm——根深度误差在绝对位姿总误差中占比超过50%。

瓶颈二：单帧PoseNet无时序消歧能力。 3DMPPE的PoseNet对每帧每人独立做2D→3D提升，无时序上下文。单目深度歧义（同一2D投影对应无穷多3D构型）在单帧条件下只能靠静态先验硬填。VNect（Mehta等，2017）在自遮挡活动（坐/躺）上PCK仅约48%；XNect（Mehta等，2019）重度遮挡时完全依赖Stage II 学习先验，缺乏显式图像证据支撑。视频时序lifting已全面证明时序上下文的价值：VideoPose3D（Pavilo等，2019）以膨胀时间卷积将感受野扩至243帧，H36M MPJPE约46.8 mm（CPN检测2D，待验证——原卡仅给出GT 2D可降低22.6 mm）；MixSTE（Zhang等，2022）以交替时空Transformer达40.9 mm；PoseMamba（2025）以线性复杂度SSM达38.1 mm（CPN检测2D，T=243），较MotionBERT精度提升1.1 mm且仅用16%计算量。但3DMPPE原框架从未引入时序lifting。

量化表现汇总：

瓶颈	量化指标	来源
根深度遮挡失效	MRPE 289 mm (Human3.6M)	Root-GAST-Net卡
自遮挡PCK	约48% (VNect坐/躺活动)	VNect卡
单帧vs时序	~46.8→38.1 mm MPJPE (H36M CPN T=243)	VideoPose3D卡 (46.8待验证) / PoseMamba卡
2D检测级联	GT 2D可再降22.6 mm	VideoPose3D卡

1.2 相关工作

按技术路线分组，仅引用cards/中存在的论文。

路线一：Top-down多人绝对位姿（根深度估计）。Moon等（2019）的3DMPPE以面积比度量开创性地解耦了根深度与根相对姿态，在MuPoTS-3D上提出MRPE/3DPCKabs/AP_root_25评估协议，推理约0.141 s/ 帧（TitanX Maxwell）；SMAP（2020）以自底向上全卷积方式回归根深度图（视场角归一化），结合深度感知部件关联实现遮挡优先级排序，推理约57 ms/ 帧且不受人数影响，但无相机内参时RtError从23.3 cm骤升至67 cm；HMOR（2020）引入层次化多人序关系（实例级/部件级/关节级深度序）作为可微排序损失，在MuPoTS-3D上PCKabs提升12.3、CMU Panoptic平均关节误差改善20.5 mm；Root-GAST-Net（2022）将时序lifting（GAST-Net，27帧）引入top-down管线，在H36M上将MRPE从289降至178 mm，MuPoTS-3D上3DPCKabs达56.8%（超TDBU_Net 8.8 pp），AP_root_25达58.9%（超12.6 pp），速度15 fps（GTX 1080，TensorRT FP32）。HDNet以GNN做多人深度分类，但依赖人体平均尺度先验，对儿童或身材异常者偏差大。

方法	年份	关键指标	根深度策略	遮挡处理
3DMPPE (Moon)	2019	MRPE 289 mm (H36M)	面积比 k	无
SMAP	2020	RtError 23.3 cm	根深度图（稀疏）	深度排序遮挡优先
HMOR	2020	PCKabs +12.3 (MuPoTS-3D)	层次序关系	训练时弱监督
Root-GAST-Net	2022	MRPE 178 mm (H36M), 3DPCKabs 56.8% (MuPoTS-3D)	面积比（同RootNet）	时序lifting 27 帧
本方案	—	目标MRPE≤150 mm (H36M)	面积比+SMPL修正+序数损失	GDN门控时序记忆

路线二：视频2D→3D时序lifting。VideoPose3D（2019）以膨胀因果卷积建立基线（243帧模型16.95M参数/33.87M FLOPs，推理~150k FPS/GP100），GT 2D可再降22.6 mm说明2D检测器是首要瓶颈；MixSTE（2022）以交替时空Transformer + seq2seq输出达CPN T=243下MPJPE 40.9 mm / P-MPJPE 32.6 mm（约33.7M参数，每帧645M FLOPs）；MotionBERT（2023）以双流DSTformer + 预训练-微调范式统一多任务，H36M SH检测2D下MPJPE约39.2 mm；PoseFormerV2（2023）利用DCT频域压缩实现任意感受野扩展且计算量不增，核心假设为”人体运动轨迹能量集中于低频分量”；PoseMamba（2025）以双向全局-局部SSM扫描达38.1 mm（CPN） / 15.6 mm（GT 2D），较MotionBERT精度提升1.1 mm且仅用16%计算量，训练于单张RTX 3090（120 epochs, batch 4, AdamW lr=2e-4）。OAHPE（2026）引入遮挡感知双路径路由（VisNet遮挡检测+ORST-DLEP遮挡路径+PDREP可见路径），H36M MPJPE 43.5 mm，模型仅2.6M参数/显存12.5 GB，但其VisNet完全依赖2D置信度阈值 $\tau=\eta=0.5$ ，在严重遮挡时路由失效——这正是本方案要解决的核心问题。

路线三：线性注意力/状态空间模型（NLP侧理论与工具）。DeltaNet（Yang等，2024）通过delta规则（ $v_{\text{new}} = v - h \cdot k$ ，即从 value 中减去 state 在 key 方向的投影）实现定向记忆替换，并以WY表示（Householder变换的紧凑乘积形式）实现分块并行训练，复杂度 $O(LCd + Ld^2)$ ；Gated Delta Networks

(Yang等, 2024) 将Mamba2标量衰减 α 与delta规则统一为 $S_t = \alpha_t S_{t-1}(I - \beta_t k_t k_t^\top) + \beta_t v_t k_t^\top$, $\alpha \rightarrow 0$ 快速清空、 $\alpha \rightarrow 1$ 精准更新, 1.3B/100B token训练, 但仍承认”固定状态维度限制检索容量, 仍需混合注意力层弥补”; Titans (Behrouz等, 2025) 提出以关联记忆损失对输入的梯度衡量”惊讶度”决定记忆写入优先级, 引入衰减机制管理有限容量, 架构含Core (有限窗口注意力) + 长期神经记忆 + 持久记忆参数三个超头; BASED (Arora等, 2024) 理论证明任何循环模型需 $\Omega(N)$ 比特状态才能完美解决MQAR, 实验证实召回密集型任务线性模型仍显著落后 (SWDE 48.06 vs 全注意力 71.92, FDA 24.41 vs 73.23)。fla库 (flash-linear-attention) 提供硬件高效的 chunk_gated_delta_rule Triton kernel, 支持 chunk_size $\in \{16, 32, 64\}$, 依赖 torch ≥ 2.7 /triton ≥ 3.3 。

路线四：几何先验与弱监督。 Ordinal Depth Supervision (Pavlakos等, 2018) 以关节间序数深度关系 (closer/farther/equal) 作为可微logistic排序损失训练ConvNet, 标注效率约每图1分钟 (17问 $\times$ 3.5s), 在H36M/HumanEva上验证弱监督可大幅消解单目歧义, 但作者承认”当架构更强时弱监督与全监督差距拉大”; HMR (Kanazawa等, 2018) 以SMPL参数化模型 (85维: 23关节轴角+10维PCA体型+弱透视相机) + 因式分解对抗先验 (25个判别器) 约束人体流形, 仅需2D标注即可训练; HybrIK指出”Naive HybrIK隐含假设预测骨骼长度等于模板骨骼长度…实际中常不成立”——这正是本方案将骨长建模为带不确定性软约束 (而非硬常数) 的动机来源。

1.3 根本性分析

3DMPPE管线的核心失效机制可归结为信号缺失的级联正反馈:

第一步：遮挡使面积信号退化。 RootNet的距离度量 $k = \sqrt{f_x f_y A_{\text{real}} / A_{\text{img}}}$ 中, A_{img} 由检测框面积近似 (data/Human36M/Human36M.py:122: `area = bbox[2]*bbox[3]`)。遮挡/截断时检测框仅覆盖可见部分, A_{img} 系统性偏小 $\rightarrow k$ 偏大 $\rightarrow Z_R$ 偏小 (人被判为更近)。这不是随机噪声而是方向性系统偏差, 无法通过数据增强或更大backbone消除。

第二步：单帧PoseNet无法自我修正。 即使根深度有误差, 若PoseNet有时序上下文, 相邻帧的一致性约束可提供隐式修正信号 (同一人连续帧的骨长/速度应平滑)。但3DMPPE的PoseNet是纯单帧的: 每帧独立回归, 无帧间信息流通, 错误根深度直接传导为绝对坐标偏差且无法被下游修正。

第三步：2D检测器在遮挡时反而更不可靠。 现代top-down检测器 (CPN/HRNet) 在被遮挡关节上常输出高置信度的错误位置 (”幻觉关节”)。OAHPE试图用2D置信度路由遮挡帧, 但其VisNet在严重遮挡时路由失效——恰在最需要遮挡处理时, 路由信号最不可靠。这构成恶性循环: 越遮挡 $\rightarrow$ 2D越不准 $\rightarrow$ 路由越失效 $\rightarrow$ 3D越崩。

为什么现有方法修不了? Root-GAST-Net虽引入了时序 (27帧GAST-Net), 但其时序建模仅用于root-relative姿态lifting, 根深度仍由单帧RootNet独立估计, 两个模块完全解耦、无信息反馈。HMOR的序关系是训练时弱监督而非推理时修正机制。SMAP的根深度图是稀疏监督 (仅根关节像素处), 对根关节本身被遮挡的场景无能为力。根本缺口在于: 缺少一个能在遮挡期保护可靠记忆、在恢复期按需读写的时序机制, 且该机制的路由信号不能依赖检测器自报置信度。

2. 方法

本方案保留3DMPPE的DetectNet→RootNet→PoseNet三模块top-down结构，以三个互补贡献逐层加固：

Contribution 1: 3DMPPE基线复现与视频化扩展

设计动机。 3DMPPE (Moon等, 2019) 是多人绝对3D位姿的标准管线，官方代码 (mks0601/3DMPPE_ROOTNET_RELEASE) 开源且结构清晰。复现该基线是后续改进的对照基础。原框架为单帧设计（每帧独立检测→估计→输出），本贡献将其扩展为视频管线：在DetectNet后接入逐人跟踪（匈牙利算法/ByteTrack），为每人维护独立的2D骨架时间序列，供后续Contribution 2/3使用。

技术细节.

3DMPPE三模块架构 (Moon等, 2019)： - **DetectNet**: Mask R-CNN人体检测，输出2D bbox。本方案替换为HRNet-W32 (deep-high-resolution-net.pytorch)，提供更精确的2D关键点（含confidence）； - **RootNet**: ResNet-50/152 backbone，输入单人crop图像，分别预测根关节2D像素坐标 (u_R, v_R) 和绝对深度 Z_R 。深度通过距离度量 $k = \sqrt{f_x \cdot f_y \cdot A_{\text{real}} / A_{\text{img}}}$ 学习 (data/dataset.py:73)，其中 f_x, f_y 为相机焦距（像素单位）， A_{real} 为人体真实面积（H36M中 bbox_real=(2000,2000) mm, config.py:38）。三模块采用分离式训练（非联合），因“两任务相关性不高，分离训练精度更高”（camera_distance_aware卡）； - **PoseNet**: ResNet-50 backbone，输入单人crop + 根关节坐标，输出root-relative 3D姿态（17关节×3坐标）。

管线结构（视频化扩展后）：

```
视频帧 → DetectNet(HRNet-W32) → 2D bbox + keypoints + confidence
      → Tracker(匈牙利算法) → 逐人轨迹 {person_i: [(x,y,conf)_t]_{t=1}^T}
      → RootNet(逐人逐帧) → Z_R(t), (u_R, v_R)(t) 绝对根深度与2D位置
      → PoseNet/GDN-Lifter(逐人) → root-relative 3D sequence
      → 反投影: X_abs = X_rel · Z_R / f + [u_R, v_R, Z_R]^T
```

RootNet根深度估计的核心公式 (Moon等, 2019; main/model.py:67-72)：

$$Z_R = \gamma_{\text{pred}} \cdot k = \gamma_{\text{pred}} \cdot \sqrt{\frac{f_x \cdot f_y \cdot A_{\text{real}}}{A_{\text{img}}}}$$

网络输出头结构 (main/model.py:67-72)：backbone最终特征 (2048×8×8) 经全局平均池化 → 2048×1×1 → 1×1 Conv (self.depth_layer, model.py:22-28, in=2048, out=1) → 标量 γ_{pred} → 乘 k 得绝对深度。由针孔模型 $A_{\text{img}} \approx f_x f_y A_{\text{real}} / Z^2$ 可推导 $k \approx Z$ （相机到人体的距离），因此 γ_{pred} 为无量纲比例修正因子，理想值为1。

视频化扩展的设计选择： - 跟踪算法选择匈牙利算法（而非更复杂的DeepSORT/ByteTrack），因为MuPoTS-3D最多3人/场景，简单算法即可胜任，且不引入额外GPU开销； - 轨迹缓存长度设为T=243帧（与PoseMamba训练窗口一致），超出时滑动窗口截断； - 身份关联失败（新目标出现/旧目标消失）时，GDN hidden state初始化为零向量（等价于无历史记忆），不强制续接。

与现有系统的衔接。 DetectNet使用HRNet-W32 (deep-high-resolution-net.pytorch仓库)，RootNet使用官方RELEASE权重 (ResNet-50 backbone, MuCo-3DHP训练)。跟踪模块为轻量级匈牙利算法，不引入额外训练

开销。视频化扩展不改变RootNet/PoseNet的模型结构，仅增加帧间身份关联。

可回退设计. 本贡献为纯工程集成，不修改任何模型结构。若后续Contribution 2/3的改进模块失效，可直接回退到本基线的逐帧推理模式，性能下界即为3DMPPE原版精度（MRPE 289 mm (H36M) / 3DPCKabs约44%，camera_distance_aware论文Table 2）。

Contribution 2: RootNet遮挡鲁棒改进（SMPL面积修正 + 序数深度监督）

设计动机. Contribution 1的分析表明，RootNet失效的根源是 A_{img} 在遮挡/截断下的系统性偏小。现有方法（HMOR序关系、SMAP根深度图）均未直接修正面积信号本身。本贡献从两个方向加固：(a) 用SMPL体型先验提供遮挡无关的 A_{real} 估计修正；(b) 用序数深度监督为RootNet提供不依赖面积精度的辅助深度信号。

技术细节.

(2a) SMPL面积修正. 核心思想：当检测框面积 A_{img} 因遮挡不可信时，用SMPL模型的投影面积作为替代/修正信号。

代码锚点（3DMPPE_ROOTNET_RELEASE repo 卡）：原始 A_{img} 的计算位于 `data/Human36M/Human36M.py:122`（`area = bbox[2]*bbox[3]`），随后在 `data/dataset.py:73` 代入 `k_value` 公式（`k_value = sqrt(bbox_real[0]*bbox_real[1]*f[0]*f[1]/area)`）。深度输出头（`main/model.py:67-72`）为 `GAP(2048×8×8)→Conv1×1(2048→1)→标量  $\gamma$ →depth = gamma * k_value`。SMPL面积修正的注入点为 `data/dataset.py:73` 的 `area` 变量：将 `area` 替换为 A_{eff} （见下式），即可在不改动网络结构的前提下修正 `k_value`。

具体实现：1. 在训练阶段，对每个GT 3D姿态拟合SMPL参数 (θ, β) （使用SMPLify或HybrIK的逆向运动学），得到体型参数 β ；2. 从 β 计算该体型的标准投影面积 $A_{\text{SMPL}}(\beta, \text{pose})$ （在给定姿态下SMPL mesh的2D凸包面积）；3. 定义面积可信度权重：

$$w_A = \sigma \left(\lambda_A \cdot \frac{A_{\text{img}}}{A_{\text{SMPL}}} - \tau_A \right)$$

当 $A_{\text{img}}/A_{\text{SMPL}} \approx 1$ 时 $w_A \rightarrow 1$ （面积可信），当比值远小于1（严重遮挡/截断）时 $w_A \rightarrow 0$ ；

4. 修正后的有效面积： $A_{\text{eff}} = w_A \cdot A_{\text{img}} + (1 - w_A) \cdot A_{\text{SMPL}}$ 。

在推理时， β 由RootNet的backbone特征经一个轻量MLP头预测（2层，隐藏维256），训练标签来自离线SMPL拟合。

接口约定：SMPL面积修正模块以plugin形式接入RootNet的面积计算环节（注入点：`data/dataset.py:73` 的 `area` 变量，参见repo卡改造点1），不改变RootNet的网络结构（原仓库无任何SMPL相关代码或依赖，需从外部引入smplx库）。当 $w_A > 0.9$ 时修正量 $< 1\%$ ，等价于无修正（加法式改造）。

(2b) 序数深度监督. 借鉴Pavlakos等（2018）的序数深度思想，为RootNet提供不依赖面积绝对精度的相对深度约束。

代码锚点 (3DMPPE_ROOTNET_RELEASE repo卡) : 当前RootNet损失为纯L1 (`main/model.py:106-113` : `loss_coord = torch.abs(coord - target_coord) * target_vis` , xyz三通道等权平均) , 无序数深度监督、无面积修正项。2D数据集通过 `target_have_depth=0` 屏蔽z轴损失。序数损失的挂载点为 `model.py:111-112` 的 `loss_coord` 计算之后 (repo卡改造点3) : `return loss_coord + lambda_ord * loss_ordinal` 。 `train.py:49` 的 `target dict` 需扩充以传入多人同帧的GT深度序标签。

在多人场景中, 同一帧内不同人的根深度存在确定的远近序关系。定义可微排序损失:

$$\mathcal{L}_{\text{ord}} = \sum_{(i,j) \in \mathcal{P}} \log \left(1 + \exp \left(-(Z_R^{(i)} - Z_R^{(j)}) \cdot s_{ij} \right) \right)$$

其中 $\mathcal{P}$ 为同帧内所有人对, $s_{ij} = \text{sign}(Z_{\text{GT}}^{(i)} - Z_{\text{GT}}^{(j)})$ 为GT序关系标签。该损失仅约束相对顺序, 不要求绝对深度精确, 因此在面积信号退化时仍能提供梯度方向。

训练时总损失: $\mathcal{L}_{\text{RootNet}} = \mathcal{L}_{\text{depth}} + \lambda_{\text{ord}} \mathcal{L}_{\text{ord}} + \lambda_{\text{SMPL}} \mathcal{L}_{\beta}$, 其中 $\mathcal{L}_{\beta}$ 为SMPL体型预测的MSE损失。

与现有系统的衔接. 序数深度监督仅在训练时生效 (多人合成数据MuCo-3DHP提供多人同帧GT), 推理时不增加计算。SMPL面积修正的MLP头参数量约0.13M, 推理额外开销可忽略。评估阶段的投影反算位于 `data/Human36M/Human36M.py:155-160` : 先将heatmap坐标映射回原图像素空间, 再调用 `pixel2cam` (`common/utils/pose_utils.py:13-18` : $X = (u - c_x) \cdot Z / f_x, Y = (v - c_y) \cdot Z / f_y$) 完成针孔模型反投影。SMPL面积修正仅改变 `k_value` 中的面积项, 不影响此反投影流程。

可回退设计. SMPL面积修正通过 w_A 门控: 初始化 $\lambda_A = 0$ 使 $w_A = 0.5$ (半修正), 若训练中发现SMPL修正引入负迁移, 可将 λ_A 固定为0使模块退化为恒等映射。序数深度为纯训练时辅助损失, 推理时零开销, 去除即回退。

Contribution 3: GDN门控Delta规则线性注意力时序Lifting (PoseNet替换)

设计动机. 3DMPPE的PoseNet为单帧逐关节回归, 无时序消歧能力。Contribution 2加固了根深度, 但root-relative姿态本身在遮挡帧仍需时序上下文修正。本贡献将PoseNet替换为基于Gated Delta Networks (GDN) 的时序lifter, 利用delta规则的”选择性记忆+快速遗忘”语义处理遮挡: 记住可见时的可靠估计, 在观测不可信时冻结记忆而非被污染。

技术细节.

(3a) 主干架构 (承PoseMamba) . 输入为每人跟踪的2D骨架序列 $(B, T, J=17, 2)$, root-centered、归一化至 $[-1, 1]$ (与PoseMamba数据预处理一致, 参见PoseMamba repo卡 `datareader_h36m.py:36`)。交替堆叠空间GDN块 (沿关节维 J 扫描) 与时间GDN块 (沿帧维 T 扫描), 每块为pre-norm残差结构 (与PoseMamba `mambablocks.py:676-680` 的 `BiSTSSMBlock._forward` 同构) :

```
# 伪代码: GDN时空块
def forward(self, x):          # x: (B, T, J, C)
    x = x + self.drop_path(self.gdn_op(self.norm(x)))  # GDN分支
    x = x + self.drop_path(self.mlp(self.norm2(x)))    # MLP分支
    return x
```

空间块输入 $(B \cdot T, J, C)$ ，序列长度 $L = J = 17$ ；时间块输入 $(B \cdot J, T, C)$ ，序列长度 $L = T$ （81或243）。输出 $(B, T, J, 3)$ root-relative序列，再与RootNet的 Z_R 反投影组合得绝对3D。

(3b) GDN核心算子（引用fla repo卡）。每个GDN块的核心调用为fla库的 `chunk_gated_delta_rule`（`fla/ops/gated_delta_rule/chunk.py:397-588`）：

```
from fla.ops.gated_delta_rule import chunk_gated_delta_rule

# q, k, v: (B, L, H, D_head)  g: (B, L, H)  beta: (B, L, H)
o, final_state = chunk_gated_delta_rule(q, k, v, g, beta,
                                         chunk_size=64) # 允许值: {16, 32, 64}
```

其递推语义（naive参考实现，`fla/ops/gated_delta_rule/naive.py:50-59`）：

```
for each timestep i:
    h = h * exp(g_i)                # 门控衰减
    v_delta = v_i - (h * k_i).sum(dim=-2) # delta: 减去当前state在k方向的投影
    v_delta = v_delta * beta_i       # beta缩放（写入强度）
    h = h + outer(k_i, v_delta)      # 外积更新
    o_i = einsum('hd,hdm->hm', q_i, h) # 查询输出
```

门控衰减公式（`fla/ops/gated_delta_rule/gate.py:96-104`）： $g = -\exp(A_{\log}) \cdot \text{softplus}(g_{\text{input}} + dt_{\text{bias}})$ ，chunk内做cumsum。

`chunk_size`约束（`fla/ops/gated_delta_rule/chunk.py:535-536`）：GDN仅允许`chunk_size` $\in \{16, 32, 64\}$ ，本方案对时间块（ $T=81/243$ ）取64，对空间块（ $J=17$ ）取16。

(3c) 双向扫描实现。fla的chunk kernel硬编码因果（下三角）mask（`fla/ops/common/chunk_o.py:125-126`：`m_A = (o_t[:, None] >= o_t[None, :])`），不直接支持双向。本方案采用与PoseMamba CrossMerge同构的策略（PoseMamba repo卡 `csms6s.py:170-192`）：正向+反向各跑一次`chunk_gated_delta_rule`，输出逐元素求和：

```
# 双向GDN
o_fwd, _ = chunk_gated_delta_rule(q, k, v, g, beta, chunk_size=C)
o_bwd, _ = chunk_gated_delta_rule(q.flip(1), k.flip(1), v.flip(1),
                                   g.flip(1), beta.flip(1), chunk_size=C)
o = o_fwd + o_bwd.flip(1) # CrossMerge: sum融合
```

这与PoseMamba的 `CrossMerge_plus_poselimbs`（`csms6s.py:186`：`ys[:, 0:2] + ys[:, 2:4].flip(dims=[-1])`）完全同构，已验证有效。

(3d) 解耦双门控（核心创新）。将GDN的写入系数beta解耦为两级门控：

观测质量门 β_{obs} （双通道关断）：

$$\beta_{\text{conf}} = \sigma(w_1 \cdot \text{conf}_{2d} + w_2 \cdot \text{bbox_area_ratio} + w_3 \cdot \text{vis_flag} + b)$$

$$\beta_{\text{geo}} = \sigma(-w_4 \cdot \text{bone_strain} - w_5 \cdot \|\mathbf{v}_t - \mathbf{v}_{t-1}\|/\sigma_v - w_6 \cdot e_{\text{reproj}} + b')$$

$$\beta_{\text{obs}} = \min(\beta_{\text{conf}}, \beta_{\text{geo}})$$

其中：- bone_strain = $\max_i \left| \frac{\|j_i - j_{\text{parent}(i)}\|_t}{\|j_i - j_{\text{parent}(i)}\|_{t-1}} - 1 \right|$ （逐骨计算取max）- e_{reproj} ：当前2D与记忆3D经 Z_R 重投影的像素误差 - 取min确保任一通道判定不可信即关断写入

通道B（几何一致性）的关键作用：当检测器输出高置信度但位置错误的”幻觉关节”时（conf > 0.8但GT标记为occluded），通道A不会关断，但骨长应变/重投影误差会异常大 $\rightarrow \beta_{\text{geo}} \rightarrow 0 \rightarrow \beta_{\text{obs}} \rightarrow 0$ ，兜底保护记忆。

状态惊讶门 g_{state} （仅在可靠帧上计算）：

当 $\beta_{\text{obs}} > \theta_{\text{obs}}$ （可学习阈值，初始化0.5）时：

$$r = \|v_{\text{new}} - h \cdot k\| \quad (\text{delta预测残差})$$

$$g_{\text{in}} = f_{\text{MLP}}(r, \Delta r / \Delta t, \text{bone_strain})$$

高 r 且 r 持续上升（真运动突变） $\rightarrow g$ 驱动 $\alpha \rightarrow 0$ 定向替换过时记忆；高 r 但单帧脉冲（检测噪声） $\rightarrow \alpha$ 保持。

有效写入系数： $\beta_{\text{eff}} = \beta_{\text{obs}} \cdot \beta_{\text{learned}}$ ，乘入 chunk_gated_delta_rule 的 beta 参数。当 $\beta_{\text{obs}} \rightarrow 0$ 时，delta规则退化为 $h_{t+1} = \alpha \cdot h_t$ （纯衰减保持），记忆不被不可靠观测污染。

(3e) 遮挡恢复逻辑. 当 β_{obs} 从 $< \theta_{\text{obs}}$ 回升至 $> \theta_{\text{obs}}$ （关节重新可见）：- 第一帧强制 $\beta_{\text{eff}} = 1$ - 若 r 小（姿态未变）： $\alpha \rightarrow 1$ ，直接读回冻结期记忆（零代价恢复）- 若 r 大（遮挡期间姿态改变）： $\alpha \rightarrow 0$ ，快速改写

(3f) 几何先验不确定性加权. 骨长恒定、RootNet根深度、2D重投影先验均不做硬约束，按各自不确定性加权为软损失。在 $\beta_{\text{obs}} < \theta_{\text{obs}}$ 的冻结期，几何先验（骨长约束+速度惯性）作为记忆位置的唯一外推修正源，修正幅度按不确定性倒数加权。

(3g) 训练损失（承PoseMamba）. GDN lifter的训练损失沿用PoseMamba的多项组合（PoseMamba repo卡 train.py:199-229）：

$$\mathcal{L} = \lambda_{3d} \mathcal{L}_{\text{MPJPE}} + \lambda_{\text{scale}} \mathcal{L}_{\text{N-MPJPE}} + \lambda_{\text{vel}} \mathcal{L}_{\text{velocity}} + \lambda_{\text{diff}} \mathcal{L}_{\text{diff}} + \lambda_{\text{lv}} \mathcal{L}_{\text{limb_var}} + \lambda_{\text{ord}} \mathcal{L}_{\text{ord}}$$

默认权重（PoseMamba-L配置）： $\lambda_{3d} = 1.0, \lambda_{\text{scale}} = 0.5, \lambda_{\text{vel}} = 20.0, \lambda_{\text{diff}} = 0.5$ ，其余为0。其中 $\mathcal{L}_{\text{MPJPE}}$ 为逐关节L2欧氏距离（loss.py:56-63）， $\mathcal{L}_{\text{velocity}}$ 为时间差分速度损失， $\mathcal{L}_{\text{limb_var}}$ 为骨长方差损失（鼓励骨长恒定）。本方案额外加入 $\mathcal{L}_{\text{ord}}$ （序数深度，仅多人训练时）和门控正则项 $\mathcal{L}_{\text{gate}} = \|\beta_{\text{obs}}\|_1$ （鼓励稀疏关断，防止门控常开退化）。

所有损失函数期望输入形状 $(N, T, 17, 3)$ （loss.py:71），与GDN lifter的输出形状 $(B, T, J, 3)$ 一致，无需适配。

与现有系统的衔接: 主干结构完全承PoseMamba (`PoseMamba.py:37-141` 的交替STE/TTE架构) , 仅将内部 `BiSTSSM` 算子 (`mambablocks.py:582`) 替换为GDN算子。PoseMamba主干的输入输出形状 (B, T, J, C) 不变, `PoseMamba.py` 无需修改 (PoseMamba repo卡确认) 。fla库要求 `torch` ≥ 2.7 、`triton` ≥ 3.3 (fla repo卡环境节) 。

可回退设计: GDN时序lifter以独立PoseNet形式存在: 若GDN训练不收敛或精度低于基线, 可直接切回3DMPPE原版单帧PoseNet (ResNet-50) , 系统退化为Contribution 1+2的水平。门控模块的 θ_{obs} 初始化为0.5、 β_{learned} 初始化为1, 等价于标准GDN (zero-init门控偏移) , 训练初期不引入额外不稳定性。

3. 实验计划

3.1 评估指标

指标	定义	当前基线值	目标值	预期改进幅度
MPJPE (H36M P1, CPN)	root-relative平均关节位置误差	38.1 mm (PoseMamba-L)	≤ 38 mm	$\geq$ 持平
MPJPE (H36M P1, GT 2D)	同上, GT 2D输入	15.6 mm (PoseMamba-L)	≤ 16 mm	$\geq$ 持平
P-MPJPE (H36M P2)	Procrustes对齐后误差	32.6 mm (MixSTE)	≤ 30 mm	$\geq 8\%$ ↓
MRPE (Human3.6M)	平均根位置误差	289 mm (RootNet) / 178 mm (Root-GAST-Net)	≤ 150 mm	$\geq 15\%$ ↓ vs Root-GAST-Net
3DPCKabs (MuPoTS-3D)	绝对PCK@150mm	56.8% (Root-GAST-Net)	$\geq 62\%$	≥ 5 pp
遮挡段恢复误差 (中/长)	被mask关节在遮挡恢复后8帧内的MPJPE	待验证 (无直接基线)	较混合门控 ↓ $\geq 5\%$	核心判据
幻觉遮挡子集误差	conf>0.8但GT occluded 帧的恢复误差	待验证	较纯通道 A ↓ $\geq 5\%$	通道B判据
记忆保持率	冻结期记忆向量与遮挡前最后帧的余弦相似度	—	>0.85	混合组预期<0.5

3.2 消融矩阵

编号	消融配置	验证假设	预期效果
Full	完整方案 (C1+C2+C3)	—	最优
(a) 混合惊讶度	去解耦, 回退为单一混合门控	范畴错误修正是否有效	中长遮挡段误差 $\uparrow \geq 3\%$
(b) 去观测质量门	仅保留状态惊讶门	遮挡期记忆保护是否必要	遮挡段记忆保持率 $\downarrow \downarrow$
(b2) 去几何通道B	β_{obs} 仅由 conf/area 驱动	检测器幻觉兜底是否必要	幻觉子集误差 $\uparrow \geq 5\%$
(c) 纯因果	去双向扫描	双向时序信息的贡献	MPJPE $\uparrow 1\text{--}2\text{ mm}$
(d) 硬先验	去不确定性加权, 骨长/深度做硬约束	软加权vs硬约束	遮挡期误差 $\uparrow$
(e) 纯 Mamba/SSM	GDN换Mamba selective_scan	隔离delta规则贡献	遮挡恢复误差 $\uparrow$
(f) θ 固定0/0.5/1	可学习阈值退化为固定	自适应阈值必要性	$\theta=0$ 全开放 $\approx$ (b); $\theta=1$ 全冻结无更新
Oracle上界	GT 2D + GT根深度 + GT遮挡 mask	系统理论上限	误差趋近GT lifting下界
Negative control	随机打乱时序顺序	时序信息是否真被利用	MPJPE退化至单帧水平

3.3 基线方法

基线	类型	来源
3DMPPE原版 (单帧RootNet+PoseNet)	top-down绝对位姿	Moon 2019, cards/
Root-GAST-Net (时序+RootNet)	top-down绝对位姿	cards/
VideoPose3D	时序lifting (膨胀卷积)	Pavillo 2019, cards/
MixSTE	时序lifting (Transformer)	Zhang 2022, cards/
PoseMamba-L	时序lifting (SSM)	2025, cards/
MotionBERT	时序lifting (预训练Transformer)	Zhu 2023, cards/
OAHPE	遮挡感知路由	2026, cards/

3.4 数据集要求与预处理

Human3.6M (主要lifting评估) : - 划分: S1/5/6/7/8训练 (约3.6M帧), S9/11测试 (17关节, 15类动作) - 2D输入: CPN检测 (含confidence通道, 原始形状 $(T, 17, 3)$), 配置 `no_conf: True` 时只取xy) + GT 2D 两组 - 切片: T=81 (训练 stride=27) / T=243 (训练 stride=81 约 1/3 重叠, 测试 stride=243 不重叠)

(PoseMamba repo卡 `datareader_h36m.py:100-107`) - 预处理: 2D坐标按相机分辨率映射至[-1,1] (`datareader_h36m.py:36`: `trainset[idx] / res_w * 2 - [1, res_h/res_w]`), 3D做root-relative (`train.py:181`: `batch_gt = batch_gt - batch_gt[:, :, 0:1, :]`) - 排除3个测试序列: `s_09_act_05_subact_02`, `s_09_act_10_subact_02`, `s_09_act_13_subact_01` (`train.py:121-123`) - 相机分辨率: $1000 \times 1002 / 1000 \times 1000$ (`datareader_h36m.py:31-33`) - 训练增强: 随机水平翻转 (`flip: True`); 测试时翻转增强 (test-time augmentation, `train.py:71-75`)

MuCo-3DHP + MuPoTS-3D (多人绝对位姿评估): - MuCo-3DHP: 40万合成多人帧 (训练), 由MPI-INF-3DHP合成多人场景 - MuPoTS-3D: 20段室内外多人视频 (测试), 最多3人/场景 - 指标: MRPE (平均根位置误差) / 3DPCKabs (绝对PCK@150mm) / AP_root_25 (根深度25cm阈值精度) - 评估使用官方脚本, GT相机内参

遮挡增强 (合成, 训练时在线生成): - 随机mask: 按概率 $p=0.3$ 随机mask关键点/帧/区域 (承P-STMO掩码预训练思路, P-STMO发现90%时间掩码率才有效暗示姿态序列高度冗余) - 结构化遮挡: 模拟另一人bbox经过导致的连续关节丢失, 持续8-32帧。设计理由: 区分检测噪声型单帧丢失 (随机mask) 与真遮挡型连续退化 (结构化), 后者是GDN门控记忆保护机制的核心验证场景 - 幻觉遮挡子集: 在结构化遮挡帧上保留检测器对错误位置的高置信度输出 ($\text{conf} > 0.8$ 但GT标记occluded)。构造方法: 从CPN检测器在遮挡序列上的实际输出中筛选高置信但高误差 (> 50 px) 的帧。专门压力测试 β_{obs} 通道B的兜底能力——若仅用通道A (conf/area), 此子集上系统完全失效

3.5 评估协议

- H36M标准协议:** Protocol #1 (MPJPE, root-relative, 单位mm) + Protocol #2 (P-MPJPE, Procrustes 对齐后计算)。评测时预测序列中心帧的root置零 (`train.py:79`: `predicted_3d_pos[:, :, 0, :] = 0`)。测试时翻转增强 (对输入序列水平翻转后推理, 输出翻转回来取平均)。
- 遮挡鲁棒性协议 (本方案新增):** 在测试序列上施加结构化遮挡 (训练时未见过的遮挡模式), 按持续长度分桶 (短<8帧/中8-32帧/长>32帧), 报告: (a) 遮挡期间被mask关节的MPJPE; (b) 遮挡恢复后8帧内的MPJPE (衡量记忆恢复质量); (c) 遮挡期记忆保持率 (冻结期GDN hidden state与遮挡前最后一帧的余弦相似度)。
- 幻觉遮挡子集协议 (本方案新增):** 仅在 $\text{conf} > 0.8$ 但GT occluded的帧上计算恢复误差, 隔离通道B的独立贡献。预期: 完整方案 vs 去通道B (消融b2) 在此子集上差异 $\geq 5\%$ 。
- MuPoTS-3D协议:** 使用官方评估脚本, 报告MRPE/3DPCKabs/AP_root_25。使用GT相机内参。
- 效率协议:** 参数量(M)、MACs(G)、推理吞吐(fps), 单卡RTX 3090, batch=1, T=81/243分别报告。使用torch.cuda.Event计时, warmup 10次后取100次平均。

3.6 计算资源估算表

阶段	模型	数据	GPU	显存峰值	预计时长
C1: 3DMPPE复现（RootNet训练）	ResNet-50	MuCo-3DHP 400K	1x24GB	~8 GB	~12 h
C1: 3DMPPE复现（PoseNet训练）	ResNet-50	H36M 3.6M帧	1x24GB	~10 GB	~24 h
C2: RootNet改进（+SMPL+序数）	ResNet-50 + MLP 头	MuCo-3DHP	1x24GB	~9 GB	~14 h
C3: GDN lifter（S规模，调试）	~4M params	H36M T=81	1x24GB	~6 GB	~6 h
C3: GDN lifter（B规模，正式）	~12M params	H36M T=243	1x24GB	~12 GB	~36 h
C3: GDN lifter（L规模，若资源允许）	~30M params	H36M T=243	1x24GB	~20 GB	~72 h
消融实验（8组xB规模）	~12M params	H36M T=243	1x24GB	~12 GB	~12 天
MuPoTS-3D评估	全管线	20序列	1x24GB	~10 GB	~2 h

注： PoseMamba-L在单张 RTX 3090 上训练120 epochs（PoseMamba卡）， 本方案GDN-B规模（dim=64, depth=8）参数量远小于PoseMamba-L（dim=128, depth=20）， 显存与时长应在24GB卡预算内。

4. 可行性评估

4.1 实现复杂度

组件	工程量	与更轻替代路线的对比
C1: 3DMPPE复现+视频化	中（集成4个仓库）	若仅复现单帧版，工程量×0.5
C2: SMPL面积修正	低（1个MLP头+离线拟合）	若用固定平均体型替代SMPL，工程量×0.3但精度损失
C2: 序数深度监督	低（1个辅助损失）	无更轻替代
C3: GDN lifter主干	中（替换PoseMamba SSM→GDN）	若直接用PoseMamba原版不做替换，工程量×0但无创新
C3: 解耦双门控	高（自定义逻辑+逐帧几何计算）	若用单一门控（消融a），工程量×0.6
C3: 双向扫描	低（正反向各跑一次+sum）	若纯因果（消融c），工程量×0.8

总复杂度倍数： 完整方案约为”仅复现3DMPPE”的3.5倍工程量。核心增量来自C3的解耦门控（约占总工程量40%）。

4.2 外部依赖风险表

依赖	版本要求	风险等级	缓解措施
fla (flash-linear-attention)	torch≥2.7, triton≥3.3	中	若triton编译失败，退回naive PyTorch实现 (fla/ops/gated_delta_rule/naive.py)，速度慢但功能等价
3DMPPE_ROOTNET_RELEASE	PyTorch 1.x 兼容	低	官方代码稳定，无活跃维护风险
HRNet (deep-high-resolution-net)	PyTorch ≥1.1	低	成熟仓库，仅用预训练权重
PoseMamba	PyTorch 1.13+, CUDA 11.7	中	需编译selective_scan CUDA扩展；若替换为GDN则可移除该依赖
SMPL模型	需注册下载	低	学术许可，离线使用
MuCo-3DHP数据	~50 GB	低	公开下载

4.3 错误传播风险

级联结构： DetectNet → Tracker → RootNet → GDN Lifter → 反投影

环节	失效模式	下游影响	最坏情况	缓解措施
DetectNet漏检	某人无bbox	该人完全丢失	无法补救 (top-down固有限制)	降低conf阈值 (牺牲精度换召回)
Tracker ID切换	两人轨迹互换	时序记忆被错误身份污染	GDN记忆写入错误序列→遮挡恢复完全错误	交叉遮挡时冻结GDN记忆更新
RootNet深度崩溃	遮挡时 A_{img} 严重偏小	绝对坐标整体偏移	MRPE退化至>300 mm (接近无修正基线)	C2 SMPL面积修正兜底
GDN门控失效	β_{obs} 误判 (该关未关)	不可靠观测写入记忆	退化至无门控GDN (≈消融b, 仍优于单帧)	通道B几何兜底
几何通道B误触发	快速运动被误判为几何违反	有效帧被错误冻结	退化至纯惯性外推 (短时<8帧影响有限)	bone_strain阈值可学习
fla kernel数值异常	Triton编译/精度问题	训练不收敛	无法使用GDN	退回naive.py PyTorch实现

最坏情况分析： 若C3的GDN lifter完全不收敛或精度低于单帧PoseNet，系统可结构性回退至C1+C2 (RootNet改进+单帧PoseNet)，此时性能下界为3DMPPE原版+SMPL面积修正，MRPE预期约250 mm (较

原版289 mm仍有改善）。若C2也失效，回退至C1纯基线（MRPE 289 mm）。回退路径为加法式：每个Contribution独立可拆除，不存在”拆一个必须拆全部”的耦合。

结构性可回退保证的设计细节：- C2的SMPL面积修正通过 w_A 门控实现加法式接入： $\lambda_A = 0$ 时 $A_{\text{eff}} = A_{\text{img}}$ （恒等），训练全程可动态关闭；- C2的序数深度为纯辅助损失（ $\lambda_{\text{ord}} = 0$ 即完全移除），不影响网络结构；- C3的GDN lifter作为独立PoseNet模块，与RootNet通过标准接口（ $Z_R + 2\text{D keypoints} \rightarrow \text{绝对3D}$ ）连接，切回原版PoseNet仅需替换一个模块文件；- C3内部的解耦门控以 $\beta_{\text{eff}} = \beta_{\text{obs}} \cdot \beta_{\text{learned}}$ 乘入，若将 β_{obs} 固定为1则退化为标准GDN（无门控），若将 β_{learned} 固定为0则退化为纯衰减（无写入）——两个极端均为有意义的退化模式而非崩溃。

Tracker ID切换的量化风险：MuPoTS-3D最多3人/场景（camera_distance_aware卡），交叉遮挡频率有限。H36M为单人数据集，训练阶段无ID切换问题。推理时若使用GT bbox（Protocol #1/2评估），跟踪误差为零。实际部署中ID切换主要影响GDN记忆的连续性，但由于门控的冻结机制（ $\beta_{\text{obs}} < \theta_{\text{obs}}$ 时不更新），切换瞬间的错误写入被限制在1-2帧内。

4.4 性能/成本量化

推理开销逐组件预算表（单帧，B规模模型，RTX 3090）：

组件	预计耗时	占比	备注
HRNet 2D检测	~30 ms	45%	使用官方预训练权重
跟踪（匈牙利）	~2 ms	3%	CPU
RootNet根深度	~8 ms	12%	ResNet-50，单人crop
SMPL面积MLP	<0.5 ms	<1%	2层MLP
GDN Lifter（B，T=81）	~12 ms	18%	chunk_size=64，双向×2
门控计算（bone_strain等）	~1 ms	1.5%	逐帧几何量，纯tensor运算
反投影+后处理	<0.5 ms	<1%	—
总计（单人）	~54 ms	—	约18 fps
3人场景	~70 ms	—	约14 fps（RootNet/GDN逐人）

对吞吐的影响：相比3DMPPE原版（~0.141 s/帧，约7 fps，TitanX Maxwell），本方案在RTX 3090上预期14-18 fps，主要得益于GDN线性复杂度（vs原版PoseNet的ResNet-50逐人推理）。

优化后预期：若使用TensorRT FP16量化HRNet+RootNet（参考Root-GAST-Net的TensorRT优化），总延迟可压至~40 ms/帧（25 fps）。GDN的Triton kernel本身已为推理优化设计。

4.5 时间线里程碑表

周次	阶段	交付物	可验收指标	风险与Go/No-Go
W1-2	环境搭建 +数据准备	H36M/MuCo-3DHP/MuPoTS-3D就绪； fla/PoseMamba/3DMPPE环境跑通	fla kernel单元测试通过 (<code>pytest tests/ops/test_gdn.py</code>)； PoseMamba官方权重复现 MPJPE $\leq$ 39 mm	Go条件： fla在目标GPU上编译成功。若失败→切换naive实现，进度不受影响
W3-4	C1: 3DMPPE复现	RootNet+PoseNet训练完成； 视频化跟踪集成	H36M MRPE $\leq$ 300 mm, MuPoTS-3D 3DPCKabs $\geq$ 45%	Go条件： MRPE $\leq$ 320 mm即可继续。若>350 mm→检查数据预处理/相机参数
W5-6	C2: RootNet改进	SMPL面积修正+序数深度监督训练完成	MRPE较C1 $\downarrow \geq$ 10% ($\leq$ 270 mm)	Go条件： 若SMPL修正无改善 (<3%)，保留序数损失、放弃面积修正，不影响C3
W7-8	C3: GDN lifter (S规模调试)	主干跑通, H36M T=81训练收敛	MPJPE $\leq$ 50 mm (S规模, CPN)	关键决策点： 若MPJPE>55 mm→执行路径A回退 (用PoseMamba原版SSM)
W9-10	C3: GDN lifter (B规模正式)	完整门控+双向, H36M T=243	MPJPE $\leq$ 40 mm (CPN)，遮挡恢复误差可量化	若门控训练不稳定→先固定 $\theta_{obs}=0.5$ 跑消融，再尝试可学习
W11-12	消融实验	8组消融+oracle+negative control	核心判据：解耦vs混合 $\downarrow \geq$ 3%；通道B幻觉子集 $\downarrow \geq$ 5%	若核心判据不满足→论文贡献重定位为C1+C2, C3作为negative result
W13-14	MuPoTS-3D全管线评估+论文撰写	完整结果表+可视化	H36M MRPE $\leq$ 150 mm, MuPoTS-3D 3DPCKabs $\geq$ 62%	若MRPE>200 mm→调整目标为”优于Root-GAST-Net” (H36M $\leq$ 178 mm)
W15-16	论文修改+答辩准备	终稿+PPT	导师审阅通过	—

关键路径分析： 最长路径为 W1→W3→W7→W9→W11→W13→W15（环境→复现→GDN调试→正式训练→消融→评估→写作），共16周无冗余。缓冲策略： C2与C3-S规模可并行（W5-8），若C2提前完成则W7全力

投入GDN。

4.6 综合判级与决策路径

综合判级：B+（可行，有明确创新点，工程风险可控）

- 创新性：解耦双门控（观测质量门+状态惊讶门）在姿态领域无先例（idea评审重0命中），且“范畴错误修正”（NLP惊讶度 $\neq$ 姿态惊讶度）有清晰理论动机。
- 工程可行性：fla库提供成熟kernel，PoseMamba提供验证过的时空架构，替换路径已被repo卡逐行锚定。主要风险在四仓库集成的调试链路。
- 资源匹配：B规模模型（~12M参数）在24GB卡上训练无压力，120 epochs约36小时。

决策路径建议：

路径A（推荐，稳健型）：W1-6完成C1+C2，确认RootNet改进有效后再启动C3。若W8时GDN-S规模MPJPE >55 mm（明显不收敛），则C3退化为“直接将PoseMamba原版SSM接入3DMPPE管线”（仍有视频化贡献），放弃自定义门控。此路径保证毕设有完整结果。

路径B（进取型）：C1/C2/C3并行推进（W3即开始GDN调试），W10前完成全部训练。若核心判据（解耦vs混合 $\downarrow \geq 3\%$ ）不满足，则论文贡献重新定位为“3DMPPE视频化+RootNet几何加固”，GDN门控作为negative result报告。此路径风险更高但上限更高。

可证伪判据（来自idea定稿）：(i) 若解耦门控组相对单一混合惊讶度组在遮挡段关节误差上无 $\geq 3\%$ 改善，则“范畴错误修正”不成立，回退原方案；(ii) 若双通道 β_{obs} （置信度+几何一致性）相对纯置信度 β_{obs} 在幻觉遮挡子集上无 $\geq 5\%$ 改善，则几何兜底通道无效，观测质量门退化为OAHPE式软阈值。这两条判据直接对应消融(a)和(b2)，在W11-12消融阶段即可判定。若两条均不满足，说明GDN门控的核心设计假设不成立，论文仍有C1+C2的贡献（视频化+RootNet加固），但C3需诚实报告为negative result。

5. 结论

本方案以3DMPPE（DetectNet $\rightarrow$ RootNet $\rightarrow$ PoseNet）为基线，通过三个递进贡献构建遮挡鲁棒的多人绝对3D位姿估计系统：(1) 复现基线并视频化扩展；(2) 以SMPL面积修正+序数深度监督加固RootNet根深度在遮挡/截断下的鲁棒性；(3) 以GDN门控delta规则线性注意力替换单帧PoseNet为时序lifter，核心创新为解耦观测质量门（双通道关断：置信度+几何一致性）与状态惊讶门，实现“遮挡期保护记忆、恢复期按需读写”。预期在Human3.6M上MRPE从289 mm降至 ≤ 150 mm，H36M MPJPE至少持平PoseMamba（38.1 mm）。主要风险为四仓库集成调试复杂度与GDN门控训练收敛性，均有结构性回退路径（加法式拆除，下界为3DMPPE原版）。时间框架16周（约4个月），单卡 ≤ 24 GB GPU预算，目标为本科毕业论文答辩。

范围边界与局限：本方案不解决以下问题：(a) 极端拥挤场景（ >5 人）的跟踪与深度歧义——MuPoTS-3D最多3人，超出此范围的泛化未做承诺；(b) 相机内参未知时的绝对深度估计——沿用3DMPPE的已知内参假设；(c) 端到端联合训练——三模块仍为分离式训练，级联误差仅通过门控机制缓解而非根本消除；(d) 跨数据集泛化（H36M $\rightarrow$ 3DPW/AGORA）——评估限于标准协议内，泛化声明需后续工作支撑。这些局限在毕设时间框架内是合理的取舍，核心贡献（解耦门控+几何加固）的有效性可在现有协议内充分验证。